



CASE DE PREVENÇÃO A FRAUDES

Érick Florentino, D.Sc.
erick.sflorentino@gmail.com

SUMÁRIO

1. ESTABELECIMENTO DO BASE LINE	3
2. TREINAMENTO DO NOVO MODELO DE MACHINE LEARNING	4
a. Pré-processamento e Algoritmos Utilizados.....	4
b. Comparação com o Modelo Atual.....	6
c. Definição do Ponto de Corte para Maximização do Lucro	8
3. CONCLUSÃO	11

1. ESTABELECIMENTO DO BASELINE

Para estabelecer o baseline, foi avaliado o score/modelo atualmente utilizado em produção sobre a base de validação, mantendo a mesma lógica operacional adotada pelo novo modelo: ordenar as transações pelo score de fraude em ordem decrescente e selecionar os 10% com maior risco. A definição desse percentual deveu-se ao fato do mesmo representar 2x o percentual de fraude existente na base.

Na base avaliada (base de avaliação, divisão obtida a partir do conjunto de dados original respeitando o % de fraude dessa base), havia 22.500 transações, das quais 1.125 eram fraudulentas. Ao analisar as 2.250 transações com maior score, correspondentes ao top 10% da base, conforme informado anteriormente o motivador, o modelo atual apresentou:

- **493 fraudes identificadas;**
- **1.757 transações legítimas bloqueadas;**
- **632 fraudes não identificadas;**
- **19.618 transações legítimas corretamente liberadas;**
- **Precisão aproximada de 21,9%;**
- **Cobertura ou recall aproximado de 43,8%;**
- **F1-score aproximado de 29,2%;**
- Aproximadamente **3,56 erros para cada fraude identificada;**
- **Lift aproximado de 4,38**, pois o top 10% concentra cerca de 43,8% das fraudes.

Esses resultados constituem o baseline contra o qual o novo modelo foi comparado.

O problema em questão (fraude) trata-se de um problema de classificação desbalanceada, a acurácia isoladamente não é uma métrica adequada. Um modelo que classificasse quase todas as transações como legítimas poderia apresentar alta acurácia, mas teria pouca utilidade para a empresa. Além disso, métricas como precisão, cobertura (recall) e F1 não são necessariamente as mais adequadas para problemas com eventos raros, como a detecção de fraudes, pois podem não refletir completamente a capacidade discriminatória do modelo. Entretanto, essas métricas possuem maior facilidade de interpretação para as áreas de negócio e permitem comparar de forma objetiva o desempenho da solução proposta em relação ao método atualmente utilizado. Embora não exista uma relação direta entre essas métricas e indicadores globais como a AUC, modelos que apresentam melhor equilíbrio entre precisão e cobertura tendem a

gerar classificações mais eficientes, podendo resultar em ganhos operacionais, redução da taxa de erro por acerto e melhor retorno financeiro da estratégia adotada.

As métricas escolhidas foram:

- **Precisão:** indica qual percentual das transações bloqueadas é realmente fraudulento. É importante para controlar o bloqueio incorreto de transações legítimas.
- **Recall ou cobertura:** mede qual percentual de todas as fraudes existentes foi identificado. É importante porque fraudes não detectadas geram perda de 100% do valor da transação.
- **F1-score:** combina precisão e recall, sendo útil para avaliar o equilíbrio entre identificação de fraudes e falsos bloqueios.
- **Average Precision e curva Precision-Recall:** são mais informativas do que a acurácia e, em muitos casos, do que a ROC-AUC quando a classe positiva é rara.
- **ROC-AUC:** mede a capacidade geral de ordenação do modelo, embora deva ser analisada em conjunto com métricas mais sensíveis ao desbalanceamento.
- **KS:** avalia a separação entre as distribuições de transações fraudulentas e legítimas.
- **Lift:** mostra quanto o modelo é melhor do que uma seleção aleatória. No baseline, o lift de aproximadamente 4,38 significa que o top 10% do score concentra cerca de 4,38 vezes mais fraudes do que uma seleção aleatória do mesmo tamanho.
- **Erros por acerto:** representa quantas transações legítimas são bloqueadas para cada fraude encontrada, facilitando a interpretação operacional.
- **Lucro líquido:** é a métrica decisiva para a definição do ponto de corte, pois incorpora simultaneamente comissão, perdas com fraude e perdas decorrentes de bloqueios incorretos.

2. TREINAMENTO DO NOVO MODELO DE MACHINE LEARNING

a. Pré-processamento e Algoritmos Utilizados

O desenvolvimento respeitou a separação entre as bases de **treino, teste e validação**. A base de validação permaneceu isolada até a avaliação final, reduzindo o risco de vazamento de dados e de resultados excessivamente otimistas.

O pré-processamento incluiu:

- Remoção de registros duplicados;
- Tratamento separado de variáveis numéricas, categóricas e binárias;
- Preservação das variáveis binárias como indicadores 0 e 1;
- Codificação das variáveis categóricas;
- Criação de características derivadas dos produtos e das transações, como presença de números, tamanho do texto, quantidade de palavras, raridade de produtos e categorias;
- Criação de indicadores relacionados ao valor da transação;
- Criação de variáveis temporais, como fim de semana, madrugada e horário comercial. Neste momento, ano e mês não foram considerados devido ao curto intervalo temporal de 2 meses.
- Seleção de variáveis utilizando apenas a base de treinamento;
- Criação de variáveis por clusterização a partir das características numéricas selecionadas;
- Aplicação, nas bases de teste e validação, somente das transformações e parâmetros aprendidos no treinamento.

Foram avaliados diferentes conjuntos de variáveis, combinando características originais, variáveis selecionadas e informações produzidas pela clusterização. Essa abordagem permitiu verificar se a segmentação dos comportamentos transacionais adicionava capacidade preditiva ao modelo supervisionado.

Os principais algoritmos de classificação considerados foram:

- **Random Forest**, utilizado como modelo baseado em conjuntos de árvores, capaz de capturar relações não lineares e interações entre variáveis;
- **XGBoost**, utilizado por sua capacidade de trabalhar com relações complexas, dados desbalanceados e otimização sequencial dos erros;
- **LightGBM**, considerado pela eficiência computacional e pelo bom desempenho em dados tabulares com grande quantidade de variáveis;
- **Regressão Logística**, utilizada como modelo estatístico de referência para classificação binária, permitindo interpretar o impacto das variáveis na probabilidade de fraude e servindo como baseline para comparação com modelos mais complexos;
- **Decision Tree**, utilizada por sua capacidade de gerar regras de decisão de fácil interpretação, identificando segmentações dos dados e relações não lineares entre as variáveis de forma intuitiva;

No que tange aos algoritmos de **clusterização**, conforme informado anteriormente, a fim de completar a análise com o objetivo de identificar grupos de transações fraudulentas que apresentassem características e comportamentos semelhantes foram testados os algoritmos **K-Means** e **K-Medoids**, variando a quantidade de clusters entre 2 e 5 grupos.

- **K-Means** foi escolhido por ser um dos métodos de agrupamento mais utilizados na literatura, apresentando boa eficiência computacional e capacidade de identificar padrões em grandes volumes de dados por meio da minimização da distância entre os registros e o centroide de cada grupo.
- **K-Medoids** foi avaliado por ser mais robusto à presença de valores extremos (outliers), uma vez que seus grupos são representados por observações reais da base, reduzindo o impacto de registros atípicos na formação dos clusters.

Além do uso exploratório para segmentação dos casos de fraude, foram realizados testes considerando a clusterização como uma abordagem para auxiliar na previsão de fraudes. Entretanto, os agrupamentos gerados não apresentaram capacidade discriminatória ou ganho preditivo relevante quando comparados aos modelos supervisionados avaliados. Diante desses resultados, a estratégia de clusterização foi descontinuada e não foi incorporada à solução final implementada. Todavia, as distância do cluster e nome dele foram usadas como features no método supervisionado. Objetivo de avaliar se poderia enriquecer o contexto, ou seja, o problema apresentado.

É válido ressaltar que longo do projeto foram conduzidos 85 experimentos, combinando 17 conjuntos de variáveis e cinco algoritmos de classificação. A otimização dos modelos foi realizada por meio de Grid Search com validação cruzada de cinco folds, totalizando 1.088 combinações de hiperparâmetros avaliadas e aproximadamente 5.525 treinamentos de modelos. Esse processo permitiu identificar as configurações com melhor desempenho preditivo e selecionar a solução mais adequada para o problema de detecção de fraudes.

b. Comparação com o Modelo Atual

A seleção do modelo final foi realizada com base na métrica **Average Precision (AP)**, por ser mais adequada a problemas de classificação com classes desbalanceadas, como a detecção de fraudes. Diferentemente da AUC, que considera simultaneamente o comportamento das classes positiva e negativa, a Average Precision enfatiza a capacidade do modelo de identificar corretamente os casos fraudulentos ao longo dos diferentes limiares de classificação. As métricas de precisão, cobertura (recall), F1-Score, AUC e taxa de erro por acerto foram empregadas como indicadores complementares para apoiar a análise dos resultados.

Após a identificação do melhor algoritmo e do melhor conjunto de variáveis, o modelo foi treinado utilizando a base de treinamento. Em seguida, as probabilidades de fraude geradas pelo modelo foram utilizadas para ordenar as transações e construir decís de risco. Esses decís, definidos a partir da distribuição observada na base de treinamento, foram aplicados à base de teste para identificar o percentual de transações que proporcionava o melhor equilíbrio entre capacidade de detecção e resultado operacional.

Uma vez definido o percentual de corte na base de teste, esse mesmo critério foi aplicado sem alterações à base de validação, garantindo uma avaliação independente e sem vies. Todo o processo foi realizado utilizando as probabilidades estimadas de fraude geradas pelo modelo.

Para possibilitar uma comparação com o método atualmente utilizado pela empresa, o mesmo procedimento foi repetido utilizando o score já existente na base. Como os decís obtidos a partir do score atual e das probabilidades do novo modelo não necessariamente concentram a mesma proporção de fraudes, a comparação final foi realizada considerando um percentual fixo de transações selecionadas (20% da base), garantindo condições equivalentes de avaliação entre os métodos.

Dessa forma, a comparação foi realizada de maneira justa, utilizando a mesma base de validação e a mesma capacidade operacional de atuação. Tanto o score atual quanto o novo modelo foram ordenados de forma decrescente, de modo que as primeiras posições correspondessem às transações classificadas como de maior risco. A partir desse ordenamento, foram selecionados os 20% registros com maior propensão à fraude em cada abordagem e comparados seus respectivos resultados preditivos e operacionais.

O novo modelo deve ser considerado superior ao baseline quando apresentar:

- Maior quantidade de fraudes identificadas dentro do mesmo percentual de análise;
- Maior precisão, reduzindo bloqueios de clientes legítimos;
- Maior recall, evitando que fraudes sejam aprovadas;
- Maior F1-score e Average Precision;
- Maior lift nos primeiros decís;
- Menor quantidade de erros por fraude identificada;
- Maior lucro líquido sob as mesmas regras financeiras.

Portanto, a conclusão não deve ser baseada somente nas medidas de avaliação dado que o foi apresentado no caso. Sendo assim para a FREEDOM, o modelo mais adequado é aquele que apresenta melhor concentração de fraudes

nas primeiras faixas do ranking e, principalmente, gera o maior resultado financeiro na base de validação.

Em suma, novo modelo apresentou maior capacidade de priorizar as transações fraudulentas nas primeiras faixas do ranking de risco quando comparado ao score atual. A comparação foi realizada sobre a mesma base de validação e utilizando o mesmo percentual de seleção, garantindo consistência entre os resultados. Além da melhoria nas métricas preditivas, o novo modelo apresentou melhor resultado econômico, tornando-se mais adequado para apoiar a decisão de aprovação ou bloqueio das transações.

c. Definição do Ponto de Corte para Maximização do Lucro

O processo de definição do ponto de corte foi baseado na estrutura financeira da FREEDOM. Considerou-se que cada transação legítima aprovada gera uma receita equivalente a 10% do valor da transação, enquanto cada fraude aprovada gera uma perda equivalente a 100% do valor da transação. Dessa forma, o resultado financeiro (Lucro Líquido) da operação foi calculado por meio da Equação 1:

$$Lucro\ Líquido = Receita - Perda \text{ (Eq. 1)}$$

Onde a Receita e Perda são identificadas por meio da Equação 2 e 3:

$$Receita = 0,10 \times Valor_{Legitimo\ Valor} \text{ (Eq. 2)}$$

$$Perda = 1,00 \times Valor_{Fraude\ Aprovada} \text{ (Eq. 3)}$$

Além disso, para cada estratégia avaliada foi calculado o ganho incremental em relação ao cenário em que todas as transações fossem aprovadas:

$$Ganho = Lucro_{Estrategia} - Lucro_{Aprovar\ Tudo} \text{ (Eq. 4)}$$

Onde, $Lucro_{Estrategia}$ trata-se do lucro obtido após aplicar o modelo e bloquear as transações consideradas de risco, $Lucro_{Aprovar\ Tudo}$ lucro obtido caso nenhuma transação fosse bloqueada. $Ganho$ é o benefício financeiro gerado pela estratégia em relação ao cenário atual de aprovação irrestrita.

Exemplificando:

- Cálculo do Lucro Líquido:

Componente	Descrição	Valor
Valor Legítimo Aprovado	Soma dos valores das transações legítimas aprovadas	R\$ 1.000.000
Comissão da FREEDOM (10%)	10% sobre o valor legítimo aprovado	R\$ 100.000
Valor Fraude Aprovada	Soma dos valores das fraudes que passaram pelo filtro	R\$ 50.000
Perda com Fraude (100%)	Prejuízo integral das fraudes aprovadas	R\$ 50.000
Lucro Líquido	Comissão – Perda com Fraude	R\$ 50.000

- Ganho em relação ao cenário de aprovar tudo

Cenário	Lucro
Aprovar todas as transações	R\$ 20.000
Utilizar o modelo de fraude	R\$ 50.000
Ganho obtido	R\$ 30.000

- Ganho em relação ao cenário atual

Indicador	Valor
Lucro aprovando todas as transações	R\$ 19.262,27
Lucro obtido pelo novo modelo	R\$ 47.577,21
Ganho em relação ao cenário atual	R\$ 28.314,94

No que tange ao ponto de corte, a escolha não foi baseada exclusivamente em métricas preditivas, como F1-Score, precisão ou cobertura. Embora a ampliação do percentual bloqueado aumente a capacidade de detecção de fraudes, ela também aumenta a quantidade de transações legítimas bloqueadas, reduzindo a receita de comissão da empresa. Assim, o objetivo foi encontrar o ponto de equilíbrio entre redução de perdas e preservação da receita operacional.

Para cada faixa acumulada (Decil 1 ao 10) foram calculados:

- Fraudes bloqueadas;
- Fraudes aprovadas;
- Transações legítimas bloqueadas;
- Receita de comissão;

- Perda com fraudes aprovadas;
- Comissão perdida por bloqueios;
- Lucro líquido;
- Ganho em relação ao cenário de aprovar todas as transações.

Inicialmente, todos os limites definidos no treinamento foram aplicados à base de teste. O corte selecionado foi aquele capaz de preservar pelo menos 85% do maior lucro observado e, entre os candidatos elegíveis, apresentar a maior cobertura de fraudes. A estratégia selecionada correspondeu ao DECIL 2 das transações de maior risco.

Posteriormente, esse mesmo ponto de corte foi aplicado sem qualquer ajuste na base de validação, garantindo uma avaliação independente e sem viés. Nessa etapa, a estratégia bloqueou aproximadamente 21,57% das transações, identificando corretamente 781 fraudes, com cobertura de 69,42%, precisão de 16,09% e F1-Score de 26,12%.

Do ponto de vista financeiro, o cenário de aprovação irrestrita de todas as transações produziria um lucro de R\$ 19.262,27. Já a estratégia baseada no novo modelo gerou um lucro líquido de R\$ 47.577,21, representando um ganho adicional de:

$$R\$47.577,21 - R\$19.262,27 = R\$28.314,94$$

Para possibilitar uma comparação justa com o método atualmente utilizado pela empresa, o mesmo procedimento foi repetido utilizando o score já existente na base. Entretanto, como os decis gerados pelo score atual e pelas probabilidades do novo modelo não necessariamente concentram a mesma proporção de fraudes, a comparação final foi realizada considerando um percentual fixo de atuação de 20% da base de validação.

Dessa forma, tanto o score atual quanto o novo modelo foram ordenados de maneira decrescente, sendo selecionados exatamente os 20% registros classificados como de maior risco em cada abordagem. Essa estratégia garante igualdade de capacidade operacional e permite comparar os métodos sob as mesmas condições de negócio.

O novo modelo foi considerado superior ao baseline quando apresentou:

- Maior quantidade de fraudes identificadas dentro do mesmo percentual de análise;
- Maior precisão;
- Maior cobertura (recall);
- Maior F1-Score e Average Precision;

- Maior concentração de fraudes nas primeiras faixas do ranking (lift);
- Menor quantidade de erros por fraude identificada;
- Maior lucro líquido sob as mesmas regras financeiras.

Os resultados mostraram que o novo modelo apresentou melhor capacidade de priorização dos casos fraudulentos, concentrando mais fraudes nas primeiras posições do ranking de risco. Considerando o cenário de Top 20% das transações, o novo modelo atingiu lucro líquido de R\$ 46.748,91, enquanto o score atual alcançou R\$ 40.813,12. Assim, o novo modelo proporcionou um ganho financeiro adicional aproximado de R\$ 5.935,79, além de apresentar melhores indicadores de identificação de fraude.

3. CONCLUSÃO

Dado o trabalho apresentado, pode-se concluir que as métricas estatísticas desempenharam papel fundamental na seleção do modelo, permitindo identificar a solução com melhor capacidade de discriminação e priorização dos casos de fraude. Inicialmente, os modelos foram comparados por meio da métrica Average Precision, complementada por indicadores como AUC, precisão, cobertura, F1-Score, lift e taxa de erro por acerto. Após a definição do melhor modelo e do conjunto de variáveis mais adequado, foi realizada a análise financeira para determinar o ponto de corte operacional que maximizasse o resultado econômico da FREEDOM.

Dessa forma, a avaliação foi conduzida em duas etapas complementares: primeiramente, a seleção técnica do modelo por meio de métricas de desempenho preditivo e, posteriormente, a definição da estratégia operacional considerando os impactos financeiros do bloqueio e da aprovação das transações. Assim, para a FREEDOM, o modelo mais adequado é aquele que apresenta bom desempenho estatístico na identificação de fraudes e que, ao mesmo tempo, gera o maior retorno financeiro quando aplicado ao processo de decisão.

Considerando o processo de seleção realizado, o modelo escolhido foi o Random Forest, treinado com o conjunto de variáveis `top_total`, por apresentar a maior Average Precision ($AP = 0,3157$) dentre todos os modelos avaliados. Após a definição do ponto de corte operacional e sua aplicação na base de validação, o modelo gerou lucro líquido de R\$ 47.577,21, representando um ganho de R\$ 28.314,94 em relação ao cenário de aprovação irrestrita de todas as transações.

Em comparação com o score atualmente utilizado pela empresa, o novo modelo apresentou melhor capacidade de priorização das fraudes, identificando um maior número de casos fraudulentos dentro da mesma capacidade operacional de análise e obtendo resultado financeiro superior. Considerando o cenário de bloqueio dos 20% registros de maior risco, o novo modelo alcançou

lucro de R\$ 46.748,91, enquanto o score atual atingiu R\$ 40.813,12, resultando em um ganho adicional de aproximadamente R\$ 5.935,79.

Dessa forma, conclui-se que o Random Forest com o conjunto de variáveis top_total apresentou o melhor equilíbrio entre capacidade preditiva e retorno financeiro, tornando-se a alternativa mais adequada para apoiar as decisões de aprovação e bloqueio de transações na FREEDOM.